電気機器研究室 2025 年度 輪講資料

電気自動車班 研究経過報告

9 月 17 日(水)　25M6302　荻野 健太

1. 概要

現在 PI 制御による減速度制御を行っているが、回転数や各素子パラメータの変更、環境の変化に対して柔軟な対応は難しい。そのため、機械学習により減速度制御を行うことを提案する。

2. 機械学習のアルゴリズム

機械学習には大きく分けて教師あり学習、教師なし学習、強化学習の 3 つのカテゴリがある。教師あり学習は、入力と出力のペアを学習し、未知の入力に対して適切な出力を予測する。教師なし学習は、データの構造を理解するために使用され、クラスタリングや次元削減などが含まれる。強化学習は、エージェントが環境と相互作用しながら報酬を最大化するための戦略を学ぶ。今回の内容では、強化学習を用いる。表 1 に強化学習のアルゴリズムを示す。Actor-Critic は、Actor が方策に基づき行動を選択し Critic が行動によって環境から状態や報酬を観測および評価をし、これを基に Actor が方策を更新する[1]。本研究では行動空間が連続で Off-policy であり、Actor-Critic の改良版に当たる DDPG(Deep Deterministic Policy Gradient)や TD3(Twin Delayed DDPG), SAC(Soft Actor-Critic)を用いる比較する予定である。

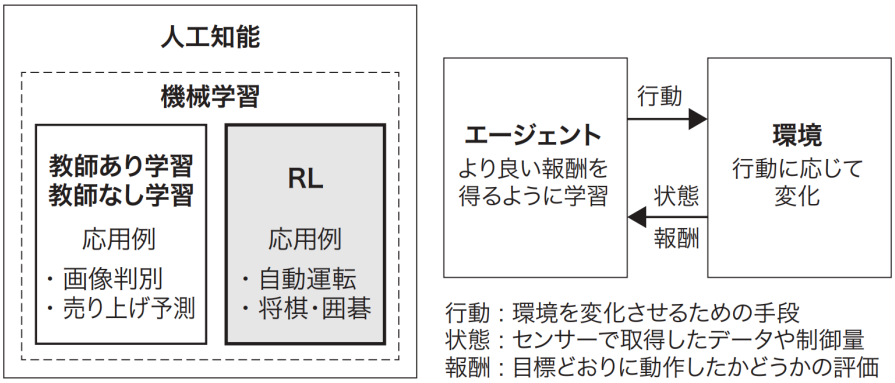


図 1　強化学習の概念図[3]

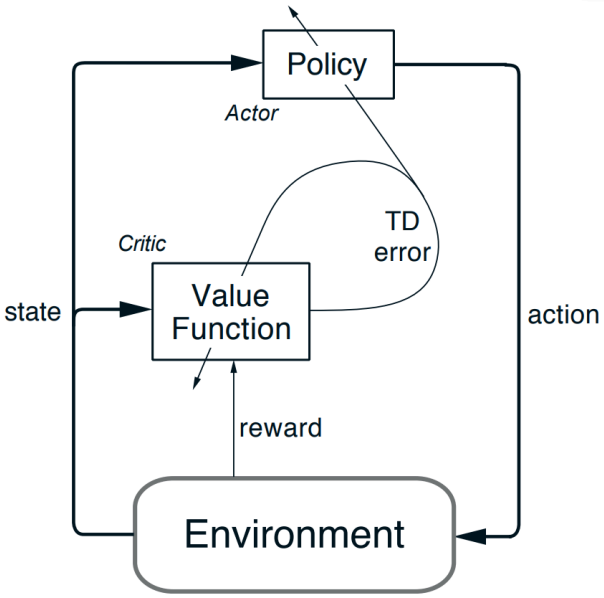


図 2　Actor-Critic の概念図[4]

表 1　強化学習のアルゴリズム一覧[2]

On-Policy エージェント

エージェント	タイプ	行動空間
SARSA	Value-base	離散
Policy Gradient	Policy-base	離散/連続
Actor-Critic	actor-critic	離散/連続
TRPO	actor-critic	離散/連続
PPO	actor-critic	離散/連続

Off-policy エージェント

エージェント	タイプ	行動空間
Q Learning	Value-base	離散
LSPI	Value-base	離散
Deep Q Network(DQN)	Value-base	離散
DDPG	actor-critic	連続
TD3	actor-critic	連続
SAC	actor-critic	離散/連続/ ハイブリッド
MBPO	model-based	離散/連続

3. 学習の構成

学習に用いる環境の構成を図 4 に示す。スイッチング素子は簡単のため理想スイッチとする。シミュレーション上での学習には Simulink の Reinforcement Learning Toolbox を用いる。Actor はスイッチング素子の PWM 入力のデューティ比を出力し、Critic には現在の環境（回転速度や減速度, 電流, デューティ比など）を入力する。報酬には目標減速度と実際の減速度の誤差を変数としたガウス関数を用いる。

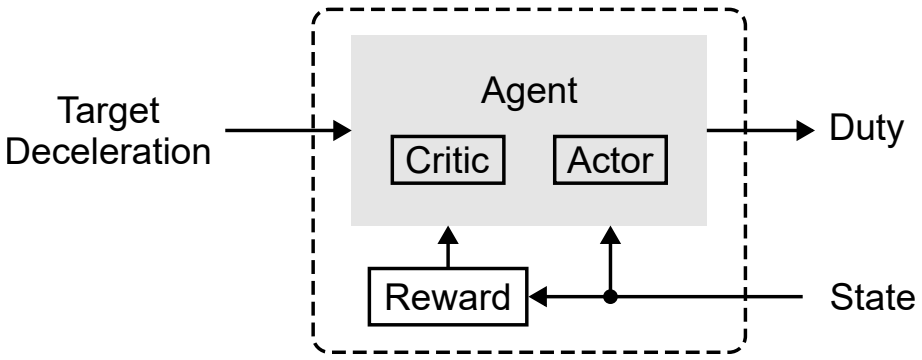


図 3　学習に用いる環境の構成

参考文献

(1) zero to one：“Actor-Critic‐AI 用語集（G 検定対応）”
https://zero2one.jp/ai-word/actor-critic/?srsltid=AfmBOooR_UL51itkx7GbKCD9umi_tnd9lRmMz_hJEkL0rFdLk8WUvHBI
(2) MathWorks：“強化学習エージェント”
https://jp.mathworks.com/help/reinforcement-learning/ug/create-agents-for-reinforcement-learning.html
(3) 東芝：“強化学習を用いた PMSM の駆動ロジック自動構築手法”
https://www.global.toshiba/content/dam/toshiba/jp/technology/corporate/review/2021/06/f01.pdf
(4) Richard S. Sutton, Andrew G. Barto：“Reinforcement Learning: An Introduction”